

DBSCAN


Date

DBSCAN = 밀도 기반 클러스터링 알고리즘

군집 만들기




- 군집수 미리 정하지 않음
- 노이즈 같은 이상치 처리 가능
- 노이즈 및 이상치 처리 효과적

ϵ = 근방 반경



$MinP_t$ = p_i 근방에 있는 최소 데이터 수


$MinP_t \geq 3$



DBSCAN 실행 과정

① 임의의 데이터 p_1 선택

②



ϵ 반경 내의 데이터 수 확인
if $p_1 = \text{Core point}$
→ 군집 형성

③ 군집 확장

! 다른 데이터에 대해서도
 ϵ 반경 체크

④ if p_2 점 = Core point

→ $p_2 - p_1$ 연결
! 군집 영역 확장

⑤ Border Point → 2 군집의 경계에 있음
Noise → 2 군집에 포함 X

TF-IDF

Date

TF: 특정 문서 안에서 해당 단어가 몇번
출현했는지 나타내는 것

↓
기본값) 문서 내에서 단어가 몇번 출현했다면,
그만큼 해당 단어 문서의 빈도수가 높을 것

ex) "A new car, new car, car review"

↓ Car 3번 출현

↓ Car: $\frac{3}{11}$ = 가장 높은
TF 값

→ Car 이 가장 중요한 단어

ex) "A Friend in need is a friend indeed"

↓ A: 2번 출현

friend: 2번 출현

→ A = friend 둘다 중요한 단어

↳ A는 상대적으로 중요한 단어 아님

→ 문제점

IDF = Inverse Document Frequency
= 역문서 빈도

↓
TF의 한계를 극복하기 위해 사용되는 개념

↓
문서의 예외처럼 문서와 연관성이 없는데
TF 값이 높은 것이 패턴이 지워짐

$$IDF = \log \left(\frac{\text{총 문서의 개수}}{\text{그 단어가 출현한 문서의 개수}} \right)$$

다) Smoothing 을 사용해
빈도에 1 더하기도 함

IDF 값이 0 이된다 = 그 단어가 중요하지 않다

$$TF-IDF = TF \times IDF$$

= 문서 빈도 X 전체 문서 중 해당 단어
빈도 고려

ex) "A new car, new car,
car review"

$$\rightarrow TF-IDF = 'Car' = 0.13$$

ex) A friend in need is
a friend indeed

TF) A = friend

TF-IDF) friend = 0.08
A = 0

LDA Topic Modeling.

Date

LDA : 각 문서가 어떤 주제 (Topic)로 구성되어 있는지 파악하기 위해 사용하는 통계 기법.

Document : 각 문서가 생성된 Topic Distribution Topic들에 몇 % 비율로 구성되어 있는지 보이기.

- 가정
- ① 문서는 여러개의 Topic로 구성되어 있다.
 - ② Topic은 여러개의 Words로 구성되어 있다.

ex) 문서 1

- A Topic 90%
- B Topic 10%

① Hyper Parameter 지정.
||
Topic의 개수

Topic
Word Distribution : 각 토픽은 주제별에 특정 언어가 얼마나 기여하느냐 확률로 표현.

② Random start
문서내의 모든 단어들 = taken 분
at, the, 이런 이런 단어들은 분포가 다르다.

ex) A Topic

- '이제까지' 단어 40%
- '가장' 단어 20%

→ 문서를 taken 들은 지정된 Topic 개수
에 랜덤하게 할당.

Topic 이름 부여
LDA 자체는 Topic에 이름 안 붙여줌.
즉, 사람이 Topic별 단어 분포에서

③ 반복 & 추정
최대 개수 할당 이후, 많은 반복 (iteration) 수행하여
추정값 업데이트

가장 높은 단어들을 확인하여 해당 Topic의 주제를 선택하고 이름을 부여해줌.

ex) A Topic

- 야구
- 축구
- 스포츠

→ 특정 문서 안의 한 단어 제외,
나머지 단어들을 모두 Topic에 몰아넣어
발생되었던 가정

→ A Topic = '스포츠' 이름 붙임.

→ 이 단어 하나만 어느 Topic에 할당되어야 가장 적절할지 추정

→ 이걸 모든 문서내의 모든 단어에 반복

→ 수행하는 지정해야 최종 출력값.

Topic 개수 결정 방법

① Perplexity : 토크수가 많아질수록

평균 perplexity는 줄어든다.

즉 이 그래프가 찍히는 걸

기준으로 삼아 Topic 개수 결정.

② Coherence = 응집도 : 한 토크에 포함된

Score

단어들끼리 얼마나

의미적으로 관련성이 있는지 측정.

→ 응집도 높은 채로 선택.


T-SNE

Date


T-SNE = Non linear Dimension Reduction

T: t-분

SNE: 확률적 이웃 검색




Manifold 가설) 데이터가 실제 있는 차원보다 낮은 차원에서 살고 있을 것이다.



Linear 방법) PCA

Non Linear 방법) MDS, LLE, Isomap, SNE

Isomap



SNE는 무엇?

SNE 원리

① Optimization 과정

② Crowding Problem.

! 고차원 공간에서 멀리 떨어진 점들을 저차원 공간에서 멀리 못해 뭉쳐버림.



T-SNE는 해결

$$\text{Cost function} = C = KL(P || Q)$$

$$= \sum_i \sum_j P_{ij} \log \frac{P_{ij}}{Q_{ij}}$$

$$\frac{\partial C}{\partial q_i} = 2 \sum_j (P_{ji} - q_{ji}) + P_{ji} q_{ji} \times (q_i - q_j)$$

q: Low 차원에서의 q

P: High 차원에서의 P

$q \approx P$ 가 목표.

$P \uparrow \rightarrow q \uparrow$

	SNE	Symmetric SNE	t-SNE
High prob	$p_{ij} = \frac{e^{-\frac{\ x_i - x_j\ ^2}{2\sigma^2}}}{\sum_{k \neq i} e^{-\frac{\ x_i - x_k\ ^2}{2\sigma^2}}}$	$p_{ij} = \frac{0}{\sum_{k \neq i} 0}$	$p_{ij} = \frac{p_{ji} + p_{ij}}{2n}$
Low prob	$q_{ji} = \frac{e^{-(\ x_i - x_j\)^4}}{\sum_{k \neq i} e^{-(\ x_i - x_k\)^4}}$	$q_{ji} = \frac{0}{\sum_{k \neq i} 0}$	$q_{ji} = \frac{(1 + \ x_i - x_j\)^{-1}}{\sum_{k \neq i} (1 + \ x_i - x_k\)^{-1}}$
Cost func	$C = \sum_i \sum_j p_{ji} \log \frac{p_{ji}}{q_{ji}}$	$C = \sum_i \sum_j p_{ji} \log \frac{p_{ji}}{q_{ji}}$	
Gradient of cost	$2 \sum_j \left(\frac{p_{ji} - q_{ji}}{1 + p_{ji} - q_{ji}} \right) (x_i - x_j)$	$\frac{4x_j}{j} (1 - \eta) (x_i - x_j)$	$\frac{1}{j} \left(\frac{1 + \ x_i - x_j\ }{1 + \ x_i - x_j\ } \right) (x_i - x_j)$