

8. Semantic Search / RAG

Date

Semantic Search


의미를 사용해 검색

RAG

관련 정보는 검색하고, 이를 LLM이 전달하여 모델이 자연적인 답변 생성 도움


밀집검색

- 동일한 임베딩 개념 사용
- 검색어를 검색 쿼리의 검색어 값으로 변환




ReRanking

- 쿼리 관련 쿼리의 관련성 정렬
- 이후 정렬에 따라 순위를 비정다
- 검색 파이프라인의 이전 단계에서 나온 검색결과 집합을 쿼리 입력받은



RAG

- RAG는 생성검색
- 검색기능 통합에 효과↓, 사용성↑
- 생성모델로 특정 데이터에 필요한 텍스트 생성시스템



8.2.1 밀집검색

- 서로 가까이 있는 포인트는 해당 텍스트가 비슷하였 의미
- 쿼리와 문장에서 가장 가까운 문서 찾기
- 밀집검색 단점
- 단점이 많이 드러나고 있는 중
- 임베딩을 즉 관련성에 대해 해석이 어렵
- 사용자가 결과를 클릭했는지 여부에 대한 정보를 모아 검색시스템 향상 가능
- 사용자가 특정 결과 정확히 원하는 결과를 알고 있을 때, 즉 키워드 매칭이 필요한 경우
- 시맨틱 검색 + 키워드 검색 = 하이브리드 검색이라고 권장

- 훈련된 모델이 이미 데이터에서 잘 작동하지 않는다
- 사용자가 어떤 정보를 요청하는 쿼리를 전달했을 때 각 문장의 관련성 여부를 알고 있는 것
- 밀집검색 시스템의 디자인 매개변수

• 텍스트 chunk로 나기기

① 문서당 하나의 벡터로 표현


② 문서당 여러개의 벡터로 표현

↳ 각 문장에 chunk가 된다


↳ 각 문장이 chunk

↳ 윈도우가 정해진 각 문장마다 chunk

↳ LLM 사용



① 벡터 DB (ReRanking) (ReRanking) (ReRanking)



(벡터DB에 저장된 문서)

가장 비슷한 벡터 검색


↳ 수백만개의 벡터 검색

(Amoy + FAISS 같은 라이브러리 사용함)


① 유사성 검색을 (fine tuning) 하기

↳ 관련 있는 쿼리를 문서에 더 가깝게,

관련 없는 쿼리를 문서에서 더 멀어지게 함.



8.2.2 ReRanking



① ReRanking 작동 방식


↳ Google encoder

↳ 모델에게 쿼리와 후보 결과를 동시에 전달.

모델이 두 텍스트를 비교 후, 이후 관련성 점수 할당.

모든 문서가 하나의 배치로 동시에 처리

② 각각의 문서가 독립적으로 쿼리에 대해 평가



8.2.3 검색 평가 지표



↳ Semantic Search는 검색 지표 (IR)로 평가됨.

↳ 검색 시스템 평가하려면 ① 텍스트 데이터


② 쿼리

③ 문서와 쿼리 사이의 관련성 판단

Text Archive



수백 개의 검색 시스템에 쿼리 전달하고 결과



쿼리에 대한 관련성 판단

이반형은 병과 중 장려한 보육 보여줌 (테스트 스위트) (Case)

쿼리1

검색시스템1 검색시스템2

1- V 1- X
2- X 2- X
3- V 3- V

시스템1 > 시스템2

(Case3) 시스템이 관련 없는 문서들

관련 없는 문서 양에 높았으면?

쿼리

테스트 스위트의 쿼리에 대해

관련 있는 문서의 총 개수

(2)

검색시스템

결과 1

실제로 쿼리

V 관련있다?

위치(K)에서

정밀도

2

3

1 V
2 V X
3 V X V

두 시스템이 모두 세개 중 하나만 관련된 결과 (Case)

다른 순위는 변환

쿼리

검색시스템1

검색시스템2

1- V 1- X
2- X 2- X
3- X 3- V

MAP으로

이치이론

정리하고 가는

$$\text{평균정밀도} = \frac{1 \times 1 + 2 \times 1}{2} = 0.8$$

MAP

→ K 위치에서 정밀도와 평균을 확장하기

테스트 스위트에 있는 모든 쿼리에 대해

검색 시스템을 평가할 수 있다. 그 측정값이

MAP

평균 정밀도 값을 쿼리 결과 평가

(Case1)

검색 시스템이 관련된 결과를

맨 위에 놓는다. → 시스템이

올바른 정답을 얻음

쿼리

테스트 스위트의 쿼리에 대해

관련 있는 문서 총 개수

(1)

검색시스템

결과 1

실제로 쿼리

V 관련있다?

위치(K)에서

정밀도

2 X
3 X

1 V
2
3

쿼리에

관련 있는

문서 개수

V (2)

V (1)

V (1)

평균정밀도

1 + 0.67

(2)

1

(1)

0.3

(1)

$$\text{평균정밀도} = \text{MAP} = 0.7$$

$$\text{평균정밀도} = \frac{1 \times 1}{1} = 1 \text{ 최상}$$

8.3 RAG

→ 많은 질문에 대해 LLM이 학습에 한

정확한 답을 낼 수 있다.

이 문제를 해결하기 위한 주요 방법

→ 관련된 문서만 계산에 곱

→ 관련 없는 문서의 정답은 무시한 계산은

그만둘 수 있다.


Q.1 RAG → 검색과 생성 기능 통합 → 환각 ↓ 사실적 출력 가능 → 로컬 데이터 사용에 적합하기 가능.	B.3.4 고급 RAG 기술 ① 쿼리 재작성 ↳ 프롬프트 / API 호출 등을 통해 수행 가능. ② 멀티 쿼리 RAG 질문 1개를 여러개의 쿼리를 검색하도록 쿼리 재작성을 확장. ↳ 근거 기반 생성 시 여러 쿼리 최상위 결과를 보편에 전달.
B.3.1 검색 → RAG 이러한 test 1 test 2	③ 멀티 스텝 RAG ↳ 더 큰 질문에 순차적인 쿼리 필요 결과 생성 ① → 근거 출처 생성 ② → 근거 출처 ④ 쿼리 라우팅 ↳ 보편에 여러 데이터베이스 검색 가능 능력 주기
이동 기반 생성 = grounded generation ↳ LLM에 제공되는 관련 정보가 특정 맥락을 형성하여 LLM이 관련 데이터에 기반을 두도록 함. 언어 모델의 Prompt	⑤ Agent RAG ↳ LLM은 작업을 LLM에게. B.3.5 RAG 평가 ① <u>유익성</u> 관련 생성된 텍스트가 얼마나 있는지 ② 생성된 답변이 <u>정확</u>한지 ③ <u>인용</u>은 정확하게 뒷받침되는지 ④ 생성된 인용 중 관련 설명도 뒷받침되는지

Graph RAG


Knowledge Graph (지식 그래프)

= 정보와 데이터 간의 관계를 구조화된 형태로 표현

ex)



ex) 구글의 지식 그래프



LLM + Knowledge Graph

LLM이 텍스트를 분석하여 지식 그래프를 생성하는데 매우 적합하다는게 확인됨

ChatGPT + 지식 그래프 그리기

Prompt

넌 지식 그래프 생성 전문가야

문장에서 Entity와 관계 추출해서

주-서-목 형태로 구성해서

이 형식 정해


지식 그래프 만들어.

결과 ex)

{ subject: 이연두, predicate: born in, object: Germany }

{ subject: 이연두, predicate: profession, object: 물리학자 }


ex)



Graph DB

DB 이름	특징
Neo4J	Graph 쿼리 언어 사용
Amazon Neptune	AWS에서 제공, 속성 그래프, RDF 지원
ArangoDB	다중 모델 DB로 그래프, 문서, 키지문
OrientDB	오픈소스, 그래프와 문서 DB 통합
TigerGraph	대규모 그래프 분석에 특화
Virtuoso	RDF 기반, Semantic Web에 강점

ex)





Cypher 쿼리 언어 MATCH (p:Person {name:'이연두'}) -[:출생지]->(c:City) RETURN c.Name

Graph RAG 작동원리

1. 사용자 질문 입력
2. Graph RAG는 Graph DB에서 관련 정보 검색
3. 검색 결과는 '주-서-목' 형식의 구조화된 정보로 추출
4. LLM이 최종 답변 생성

Graph RAG Vs 전통적 RAG

	전통적 RAG	Graph RAG
사용 DB	Vector DB 	그래프 DB 
검색 방식	검색 문장들과 DB 내 문장들 간의 Similarity 검색	개체 간의 Relationship 기반 구조적 검색
추출	유사도가 높은 text chunk	주어-서술어-목적어 형태의 구조화된 정보 추출
최종 출력	검색된 문장들을 바탕으로 LLM이 답변 생성	관계 정보를 바탕으로 LLM이 문장 구성