

12. Generative AI 의 fine tuning

Date

o 사전 훈련된 text 생성 모델을 fine tuning 하기

↳ 베이스 모델을 fine tuning을 통해
지시 수행과 같은 특정 사례에 적용.

12.1 LLM 훈련의 3단계

12.1.1 언어 모델

↳ 하나의 단계의 사전 text dataset에서
사전 훈련하는 것.

↳ self supervised learning

↳ 베이스 모델


↳ pretrained model / foundation model

12.2.1 full fine tuning

↳ 타겟 작업에 맞추어 모델의 모든
파라미터를 업데이트

↳ 사전 훈련 : 대용량 data

↳ full fine tuning : 적은 data



↳ 질문 - 응답 데이터를 사용함

ex) 지시 데이터

작업 질문 답변

(지시: _____)

(출력: _____)

작업 질문 답변

(지시: _____)

(출력: _____)

12.1.2 지도학습 fine tuning

↳ 지도학습 fine tuning으로 베이스 모델을
지시에 맞게 적용시킬 수 있다.

↳ 베이스 모델의 parameter가 지시 수행과 같은
타겟 작업에 더 잘 맞도록 업데이트됨.

↳ 다음 토큰 예측 (기본)

+ 사용자의 입력 기반으로 훈련 수행

↳ 즉, full fine tuning 동안 모델이

지시를 받아, 다음 토큰 예측 작업을

출력에 적용

즉 질문생성 X 지시 따르는 것

12.1.3 신호 fine tuning

↳ AI 언어와 사람의 신호에 맞는
행동을 하도록 만든다.

↳ 신호 튜닝 = fine tuning의 한 형태

↳ 전달하는 데이터에 의해 정의된 신호에
모델의 출력을 맞춤.

↳ 훈련과정에서 출력에 대한 신호를 추출하는
부적절한 이득.

12.2.2 파라이지 호환적인 fine tuning

= PEFT

비대역


↳ 트랜스포머 안에 임의의 모듈식 구성요소 추가

↳ 그 모듈을 fine tuning 하라


모델의 가용성 유지 X 특정 작업에서 성능 향상

↳ 시간, 계산량 절감

12.2 지도 학습 fine tuning



ex) transformer block




→ 즉 신경망 속 특정 위치에

fine tuning 할 수 있는 적응기의 W를 추가

→ 어댑터의 가중치는 동결됨

→ 특정 작업에 특화된 어댑터들은 같은 신경망 안에서 서로 교체할 수 있다.

ex) transformer stack




• LoRA

→ 어댑터의 대안.

→ 효과적인 PEFT 기법으로 널리 사용됨.

→ 모델에 추가 X. 베이스 모델 일부분만




→ 빠르게 fine tuning이 가능


방법) ① 원본 LLM의 큰 행렬을 작은 행렬로

근사하는 parameter 부분결합 만들

② 그 작은 행렬을 fine tuning



③ 그걸 동결된 원본 행렬과 결합



이론만 많음

→ 위에서 원본 W를 작은 행렬로 만들기

전체 메모리 요구량을 줄여 LoRA의 활용
증대 가능.

→ LLM의 가중치는 특정 정밀도의 수치가

→ float64 or float32 같은 여러개의 비트

→ 비트를 줄이면, 정확도가 ↓ 낮아지고,

메모리 요구량 ↓ 적어진다.

양자화 (quantization)

→ 원본 가중치 값을 정확히 나타내면서 비트 수를

줄이는 것이 목적.


→ bit 비슷한 가중치가 동일하게 재구성될 수 있

문제 가능.

ex) 원본 가중치

양자화된 가중치

재구성된 가중치




Q LORA

↳ LORA의 영향과 버전


↳ 원본 LORA와 3배 차이 나지 않음,
높은 비트의 값을 낮은 정밀도 비트거나
그 반대로 바꾸는 방법 있음.

↳ 블록 단위 연산 : 높은 정밀도 값의
특정 블록을 낮은 정밀도 블록 매핑.

예시 : 비트 매핑이 아닌, '추가 블록'을 만들어서
비슷한 가중치끼리 연산하심.



↳ 블록은 고려한 블록 : 일반적으로 $W \in [-1, 1]$ 의 가중치만 집합블록을 따라서
원본과 유사하게 학습된 블록에 따라 구성된
높은 비트에 매핑이 가능.



↳ 가중치의 상대적 비트 고려

8 이상 16 비트를 구간 $\uparrow$

↳ 16 비트는 4비트로 압축할 수 있게 된다.

↳ LLM 양자화 $\uparrow \rightarrow$ VRAM $\downarrow$

$\rightarrow$ 추론 성능 $\uparrow$

↳ 이진 양자화 / pyqnt optimizer 사용
최적화 기법 있고 손실에 자제화 되지 않음.

↳ 매개변수

① num_train_epochs : 훈련 반복 횟수, 낮게 하거나
높다

② learning rate : 가중치 업데이트를 위한 step size

③ lr_scheduler_type : 학습률 조정

④ optim : LORA의 레이어 기반 optimizer 사용

2.4 생성성 모델 평가

↳ Generative AI를 평가한다는 것은 매우 어렵

↳ 원본이 갖고 있는 학문적으 출력을 만들어서
가장한 평가 방법이 필요하고 여전히 golden
standard (참고 표준)은 없다.

2.4.1 단어 수준 지표

↳ word-level 평가

↳ 참조 dataset과 생성된 dataset을
동일 수준에서 비교.

↳ F1 score / ROUGE / BLEU / BERTScore

↳ (참고) 언어 모델이 텍스트를 얼마나 잘
예측하는지 측정.

지문으로 예측률 $\uparrow \rightarrow$ 모델 성능 $\uparrow$ (이런 평가)

↳ 원본성 / 유창성 / 지능성 고려 X.

문은 모델의 신뢰성 이해에는 유용. 반영 X.

2.4.2 벤치마크

↳ 기계적 언어 이해 / 수학 문제 등

Generative AI는 속제하는 시험에 강함

ex) MMLU : 문해/과학/철학/역사

GLUE : 다양한 언어로 언어 이해적인

TruthfulQA : 텍스트의 진실성 측정

GSM 8k, Halla Small

1) LLM 단점은 이런 벤치마크에서
답변만 잘 내려고 overfitting 될
가능성↑

↳ 매우 구체적인 사용 사례 대비 X.

↳ GPU 소모 → 확보하기 어렵다.


12.4.3 리터보스

↳ Open LLM Leaderboard

! 모델이 새겨 출시될 때마다 여러
벤치마크 기반의 성능 평가

12.4.4 자동평가

↳ LLM-as-a-judge



↳ 개방형 질문은 자동 평가 가능.

12.4.5 사람 평가


↳ Chatbot Arena

! 사용자가 두 LLM의 응답 각각 중
더 나은거 투표하는 방식.

↳ 무엇보다 중요한 최고의 평가자는
나 자신이다!

12.5 선호도 튜닝 | 장려 | RLHF

↳ LLM이 응답을 만들 때, 사람에게
선호도표를 평가하도록 하는 것.





(Case1) 만약 선호도점수↑ → 그 응답 더 생생하게
모델을 업데이트

(Case2) 만약 선호도점수↓ → 이런 생생 못하네
모델을 업데이트


12.6 보상 모델 → 선호도 평가 자동화

① reward 모델 훈련이 필요.




12.6 보상 모델 훈련

1) Dataset




2) 선호도 데이터 생성



3) reward model 훈련

① 좋은 생성에 정수 매김

② 나쁜 생성에 정수 매김



2.6.3 보상 모델 훈련

→ PPO의 장점

· Reward model 이 LLM을 돌아 훈련하는 복잡함.

→ 비용 ↑

→ DPO: PPO의 대안.

→ 강령 학습 X.

→ Reward model 대신에

LLM이 스스로 추론하게 함.

→ LLM의 보상을 활용하여 학습.


→ 수렴된 버전과 거절한 버전의

결과에서 강령을, 훈련 비용을 낮추기 위한.

이제 1) 선호 데이터 수집

2) Reward 모델 훈련

3) LLM fine tuning ← reward model 사용
(선호도 평가자로 동작)




PPO


→ 훈련된 reward model로 LLM을 fine tuning 하는 방법.

→ 지시 기반을 투입된 LLM 출력물에
잘리 쓰이는 강화학습 기법.

→ 거절된 버전과 LLM이 거절된 버전

→ data point 형태로 수집.





→ DPPO > PPO

더 강력함, 정확

→ 수많은 샘플 만드는 데에 더 효율적,
거부된 샘플 만드는 데에 덜 효율적

Parameter 최적화,